

Tabelle 1: Zusammensetzung des Evaluationsdatensatzes.

API	Fälle	PPP	PPF	PFN	FNN
EDX	52	14	10	14	14
Resistance	30	15	0	15	0

Ein Mitglied pro Fall. P = PASS, F = FAIL, N = NOT_APPLICABLE.

Tabelle 2: Gebundene Versuchsparameter.

Parameter	Wert
Experiment	10003
Dataset	3
Prompt	P2 / checklist / v1
Output mode	format_json
Output interface	output-interface-v2
Repetitions and seeds	1: 101; 2: 202; 3: 303
Schedule	dataset-position-model-repetition-v1
Schedule seed	0
Ollama	0.35.1
Experiment Python	3.12.14
CPU	Apple M5 Pro
RAM (GiB)	64.0
OS	ProductName: macOS ProductVersion: 27.0.1 BuildVersion: 26A434
Qwen model	qwen3.6:27b
Qwen quantization	Q4_K_M
Gemma model	gemma3:27b
Gemma quantization	Q4_K_M
Mistral model	mistral-small3.2:24b
Mistral quantization	Q4_K_M
draft_num_predict	0
min_p	0.000
num_ctx	32768
num_predict	512
repeat_last_n	64
repeat_penalty	1.000
stream	False
temperature	0.200
Qwen think	False
Gemma think	not set (null)
Mistral think	not set (null)
timeout_seconds	300
top_k	40
top_p	0.900

Quelle: archiviertes Setup und Manifest. think: null bedeutet nicht gesetzt. Vollständige Hashes und Quellenpfade stehen im zugehörigen CSV. Keine Ergänzung aus älteren Experimenten.

Tabelle 3: Binäre Abdeckung und Konfusionszählungen.

Modell	Abdeckung	%	TP	TN	FP	FN
Qwen	246/246	100,0 %	159	87	0	0
Gemma	246/246	100,0 %	87	81	6	72
Mistral	200/246	81,3 %	84	80	7	29

INCONSISTENT ist positiv. TP/TN/FP/FN beziehen sich nur auf verfügbare binäre Urteile. Mistral: 42 inkohärente NNN-Ausgaben und vier Parserfehler sind ausgeschlossen, keine zusätzlichen FN.

Tabelle 4: Bedingte binäre Kennzahlen.

Modell	Abdeckung	Positiv-Abdeckung	Precision	Recall	F1
Qwen	246/246	159/159	100,0 %	100,0 %	100,0 %
Gemma	246/246	159/159	93,5 %	54,7 %	69,0 %
Mistral	200/246	113/159	92,3 %	74,3 %	82,4 %

Precision, Recall und F1 sind auf verfügbare binäre Urteile bedingt. Die Abdeckung gehört zur Interpretation; fehlende Urteile werden nicht imputiert.

Tabelle 5: Übereinstimmung der vollständigen Kategoriezustände.

Modell	Kat.	Zustand K/N	%	Falsch anwendbar	Falsch N/A
Qwen	C1	246/246	100,0 %	0	0
Qwen	C2	246/246	100,0 %	0	0
Qwen	C3	246/246	100,0 %	0	0
Gemma	C1	204/246	82,9 %	0	0
Gemma	C2	204/246	82,9 %	42	0
Gemma	C3	168/246	68,3 %	42	0
Mistral	C1	200/246	81,3 %	0	42
Mistral	C2	242/246	98,4 %	0	0
Mistral	C3	206/246	83,7 %	0	0

Zustand K/N umfasst PASS, FAIL und Referenz-NOT_APPLICABLE. N enthält Parserfehler.
Falsch anwendbar: Referenz N/A, gültige Prediction PASS/FAIL. Falsch N/A: Referenz anwendbar,
Prediction N/A.

Tabelle 6: Vektorkorrektheit nach Referenzgruppe und API.

Block	Gruppe	Fälle	Qwen	Gemma	Mistral
Referenz	PPP	29	87/87	81/87	80/87
Referenz	PPF	10	30/30	0/30	1/30
Referenz	PFN	29	87/87	87/87	83/87
Referenz	FNN	14	42/42	0/42	0/42
API	EDX	52	156/156	84/156	84/156
API	Resistance	30	90/90	84/90	80/90

Modellspalten: vollständig richtige Vektoren / geplante Bewertungen. Referenz- und API-Blöcke sind separate Gruppierungen desselben Datensatzes.

Tabelle 7: Vorhandene Vergleiche innerhalb des Main-Datensatzes.

Vergleich	Paare	Qwen	Gemma	Mistral
EDX: C1-Regression	8	24/24	0/24	0/24
EDX: C2-Regression	8	24/24	0/24	1/24
EDX: konformer Zustand	8	24/24	0/24	1/24
EDX: Formatkontrolle	1	3/3	0/3	0/3
Resistance: Request-Kontrolle	1	3/3	0/3	3/3
Resistance: C2-Regression	13	39/39	39/39	33/39

Modellspalten: beide Vektoren korrekt / geplante Paar-Wiederholungen. 39 Verknüpfungen; Kontrollen sind keine automatisch inkonsistenten Fälle.

Tabelle 8: Vektorkorrektheit und Ausgabeabdeckung.

Modell	K/N	K/N (%)	K/V	V/N	Parserfehler	Technische Fehler
Qwen	246/246	100,0 %	246/246	246/246	0	0
Gemma	168/246	68,3 %	168/246	246/246	0	0
Mistral	164/246	66,7 %	164/242	242/246	4	0

K: vollständig richtige Vektoren; N: geplante Bewertungen; V: gültige Ausgaben. K/N ist die primäre Kennzahl.

Tabelle 9: Stabilität und Korrektheit der Dreiergruppen.

Modell	3/3 korrekt	Stabil falsch	Variabel	Unvollständig	Identisch/Vollst.
Qwen	82	0	0	0	82/82
Gemma	56	26	0	0	82/82
Mistral	53	25	2	2	78/80

Die Segmente beziehen sich jeweils auf 82 Fälle. Die Identitätsrate ist auf vollständige gültige Dreiergruppen bedingt.

Tabelle 10: Vollständige vorhandene RQ1-Übersicht.

Kennzahl	Qwen	Gemma	Mistral
planned	246	246	246
valid	246	246	242
parser_failure	0	0	4
technical_failure	0	0	0
valid_incorrect	0	78	78
exact_correct	246	168	164
exact_planned	1.0000	0.6829	0.6667
exact_valid	1.0000	0.6829	0.6777
valid_coverage	1.0000	1.0000	0.9837
binary_available	246	246	200
binary_coverage	1.0000	1.0000	0.8130
incoherent	0	0	42
binary_correct	246	168	164
binary_planned	1.0000	0.6829	0.6667
binary_conditional	1.0000	0.6829	0.8200
tp	159	87	84
tn	87	81	80
fp	0	6	7
fn	0	72	29
precision	1.0000	0.9355	0.9231
recall_conditional	1.0000	0.5472	0.7434
f1_conditional	1.0000	0.6905	0.8235
reference_positive	159	159	159
available_positive	159	159	113
positive_coverage	1.0000	1.0000	0.7107
tp_over_all_reference_positive	1.0000	0.5472	0.5283
runs_with_applicability_error	0	42	42

Tabelle 11: Vollständige vorhandene RQ3-Stabilitätsübersicht.

Kennzahl	Qwen	Gemma	Mistral
cases	82	82	82
complete_valid_triples	82	82	80
triple_coverage	1.0000	1.0000	0.9756
identical_triples	82	82	78
identical_given_complete	1.0000	1.0000	0.9750
all_three_correct	82	56	53
all_three_correct_rate	1.0000	0.6829	0.6463
stable_wrong	0	26	25
variable	0	0	2
two_plus_one	0	0	2
three_different	0	0	0
incomplete	0	0	2
complete_binary_triples	82	82	66
identical_binary_triples	82	82	64

Tabelle 12: Qwen: vollständige Übersicht der Wiederholungen.

Kennzahl	Wiederholung 1	Wiederholung 2	Wiederholung 3
seed	101	202	303
planned	82	82	82
valid	82	82	82
parser_failure	0	0	0
technical_failure	0	0	0
valid_incorrect	0	0	0
exact_correct	82	82	82
exact_planned	1.0000	1.0000	1.0000
exact_valid	1.0000	1.0000	1.0000
valid_coverage	1.0000	1.0000	1.0000
binary_available	82	82	82
binary_coverage	1.0000	1.0000	1.0000
incoherent	0	0	0
binary_correct	82	82	82
binary_planned	1.0000	1.0000	1.0000
binary_conditional	1.0000	1.0000	1.0000
tp	53	53	53
tn	29	29	29
fp	0	0	0
fn	0	0	0
precision	1.0000	1.0000	1.0000
recall_conditional	1.0000	1.0000	1.0000
f1_conditional	1.0000	1.0000	1.0000
reference_positive	53	53	53
available_positive	53	53	53
positive_coverage	1.0000	1.0000	1.0000
tp_over_all_reference_positive	1.0000	1.0000	1.0000
runs_with_applicability_error	0	0	0

Tabelle 13: Gemma: vollständige Übersicht der Wiederholungen.

Kennzahl	Wiederholung 1	Wiederholung 2	Wiederholung 3
seed	101	202	303
planned	82	82	82
valid	82	82	82
parser_failure	0	0	0
technical_failure	0	0	0
valid_incorrect	26	26	26
exact_correct	56	56	56
exact_planned	0.6829	0.6829	0.6829
exact_valid	0.6829	0.6829	0.6829
valid_coverage	1.0000	1.0000	1.0000
binary_available	82	82	82
binary_coverage	1.0000	1.0000	1.0000
incoherent	0	0	0
binary_correct	56	56	56
binary_planned	0.6829	0.6829	0.6829
binary_conditional	0.6829	0.6829	0.6829
tp	29	29	29
tn	27	27	27
fp	2	2	2
fn	24	24	24
precision	0.9355	0.9355	0.9355
recall_conditional	0.5472	0.5472	0.5472
f1_conditional	0.6905	0.6905	0.6905
reference_positive	53	53	53
available_positive	53	53	53
positive_coverage	1.0000	1.0000	1.0000
tp_over_all_reference_positive	0.5472	0.5472	0.5472
runs_with_applicability_error	14	14	14

Tabelle 14: Mistral: vollständige Übersicht der Wiederholungen.

Kennzahl	Wiederholung 1	Wiederholung 2	Wiederholung 3
seed	101	202	303
planned	82	82	82
valid	80	82	80
parser_failure	2	0	2
technical_failure	0	0	0
valid_incorrect	26	25	27
exact_correct	54	57	53
exact_planned	0.6585	0.6951	0.6463
exact_valid	0.6750	0.6951	0.6625
valid_coverage	0.9756	1.0000	0.9756
binary_available	66	68	66
binary_coverage	0.8049	0.8293	0.8049
incoherent	14	14	14
binary_correct	54	57	53
binary_planned	0.6585	0.6951	0.6463
binary_conditional	0.8182	0.8382	0.8030
tp	27	30	27
tn	27	27	26
fp	2	2	3
fn	10	9	10
precision	0.9310	0.9375	0.9000
recall_conditional	0.7297	0.7692	0.7297
f1_conditional	0.8182	0.8451	0.8060
reference_positive	53	53	53
available_positive	37	39	37
positive_coverage	0.6981	0.7358	0.6981
tp_over_all_reference_positive	0.5094	0.5660	0.5094
runs_with_applicability_error	14	14	14